Hurtownie danych - Spr. 3.

PWr. WIZ, Data: 21-22.03.2022

Student		Ocena
Indeks	<u>256305</u>	
Imię	<u>Grzegorz</u>	
Nazwisko	<u>Dzikowski</u>	

Zestaw składa się z 4 zadań. Jeżeli nie potrafisz rozwiązać zadania, to próbuj podać, chociaż częściowe rozwiązanie lub uzasadnienie przyczyny braku rozwiązania. Pamiętaj o podaniu nr. indeksu oraz imienia i nazwiska.

Baza danych: AdventureWorks

Zad. 1.

Należy przygotować raport umożliwiający ocenę pracowników na podstawie sumarycznej sprzedaży zrealizowanej przez pracowników w poszczególnych latach.

Raport powinien zawierać dane zgodnie z tabelą 1. Raport należy przygotować bez użycia funkcji okienkowych (klauzula OVER)

Tab. 1. Wykaz pracowników oraz wypracowane przez nich kwoty w poszczególnych latach wraz z liczbą obsłużonych zamówień

Pracownik	pracID	Rok zamówienia	Kwota	Liczba zamówień
Jiang, Stephen	274	2011	28926.25	4
Jiang, Stephen	274	2012	453524.52	22
		•••		•••
Blythe, Michael	275	2011	875823.83	65
Blythe, Michael	275	2012	3375456.89	148
				•••

Rek: ?/?

Rozwiązanie:

```
USE AdventureWorks2019;
SELECT
      CONCAT_WS(', ', LastName, FirstName) as [Pracownik],
      SalesPersonID as pracID,
      YEAR(Sales.SalesOrderHeader.OrderDate) as [Rok zamówienia],
      SUM(Sales.SalesOrderHeader.SubTotal) as [Kwota],
      COUNT(SalesOrderID) as [Liczba zamówień]
FROM Sales Sales Person
JOIN Sales.SalesOrderHeader
      ON Sales.SalesOrderHeader.SalesPersonID = Sales.SalesPerson.BusinessEntityID
JOIN Person.Person
      ON Person.Person.BusinessEntityID = Sales.SalesOrderHeader.SalesPersonID
GROUP BY
      SalesPersonID,
      YEAR(Sales.SalesOrderHeader.OrderDate),
      LastName,
      FirstName
ORDER BY SalesPersonID, [Rok zamówienia];
```

Pracownik	pracID	Rok zamówienia	Kwota	Liczba
				zamówień
Jiang, Stephen	274	2011	28926.2465	4
Jiang, Stephen	274	2012	453524.5233	22
Jiang, Stephen	274	2013	431088.7238	14
Jiang, Stephen	274	2014	178584.3625	8

Rek 4/58

Zad 2.

Należy przygotować raport umożliwiający ocenę pracowników na podstawie sumarycznej sprzedaży zrealizowanej przez pracowników w poszczególnych latach (raport powinien zawierać dane zgodnie z tabelą 1.). Raport należy przygotować wykorzystując klauzule OVER

Rozwiązanie:

```
USE AdventureWorks2019;
WITH Raport_Oceny(Pracownik, pracID, [Rok zamówienia], Kwota, [Liczba zamówień])
(
       SELECT
              CONCAT_WS(', ', LastName, FirstName),
              SalesPersonID,
              YEAR(OrderDate),
              SUM(SubTotal) OVER (PARTITION BY SalesPersonID, YEAR(OrderDate)),
              COUNT(SalesOrderID) OVER (PARTITION BY SalesPersonID, YEAR(OrderDate))
       FROM Sales.SalesOrderHeader
              JOIN Person.Person
                    ON Sales.SalesOrderHeader.SalesPersonID = Person.Person.BusinessEntityID
)
SELECT
       DISTINCT *
FROM Raport_Oceny
ORDER BY pracID, [Rok zamówienia]
```

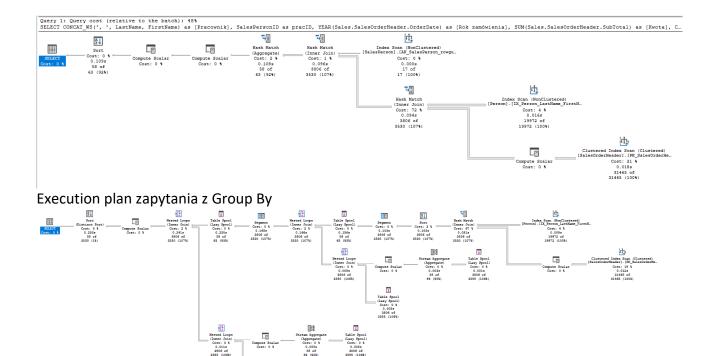
Pracownik	pracID	Rok zamówienia	Kwota	Liczba
				zamówień
Jiang, Stephen	274	2011	28926.2465	4
Jiang, Stephen	274	2012	453524.5233	22
Jiang, Stephen	274	2013	431088.7238	14
Jiang, Stephen	274	2014	178584.3625	8

Rek 4/58

Zad 3.

Ocenić jakość rozwiązań zaproponowanych w poprzednich dwóch zadaniach. Które z nich jest korzystniejsze i dlaczego, biorąc poda uwagę plany wykonania obu zapytań

Rozwiązanie:



Execution plan zapytania z Partition Over

W obu zapytaniach większość kosztu zapytania zabiera Query z obu tabel, oraz JOIN ich obu. GROUP BY jest realizowany przez jedną operację "Hash Match 'Aggregate'". W przypadku partition by, mamy dużo więcej operacji, dużo zagnieżdżonych pętli, oraz kilkukrotne odniesienie do tabeli wejściowej. Całość wykonuje się w takim samym czasie przy tej ilości danych.

Partition by specyfikuje kolumnę do agregacji, i zawsze zwraca tyle samo elementów, ile wejście. Natomiast group by automatycznie zwraca tylko 1 rekord per wartość agregowana.

Według mnie group by sprawdza się lepiej w tradycyjnych agregacjach, gdzie chcemy widzieć tylko jedną wartość agregracji. Natomiast partition by przydaje się w bardziej zaawansowanych zastosowaniach, np. szczegółowe raporty

Zad. 4.

Źródło danych:

Baza danych: AdventureWorks

Narzedzia:

Microsoft SQL Server Management Studio, Tableau

Etap 1.

Utworzyć bazę danych (o ile nie istnieje) o nazwie zgodnej z identyfikatorem studenta, a następnie utworzyć tabele (skrypt CREATE TABLE) zgodnie z poniższą specyfikacją:

a. Dim_Customer (CustomerID, FirstName, LastName, TerritoryName, CounrtyRegionCode, Group)

Tabele źródłowe:

SalesTerritory

- Customer
- Person

Rozwiązanie:

```
USE [256305];
WITH Customer Source
       CustomerID,
       FirstName,
       LastName,
       TerritoryName,
       CountryRegionCode,
       [Group]
) AS
       SELECT
              CustomerID,
              FirstName,
              LastName,
              [AdventureWorks2019].[Sales].[SalesTerritory].[Name],
              [AdventureWorks2019].[Sales].[SalesTerritory].[CountryRegionCode],
              [AdventureWorks2019].[Sales].[SalesTerritory].[Group]
       FROM [AdventureWorks2019].[Sales].[Customer]
              LEFT JOIN [AdventureWorks2019].[Person].[Person]
                     ON [AdventureWorks2019].[Person].[Person].BusinessEntityID =
[AdventureWorks2019].[Sales].[Customer].CustomerID
              LEFT JOIN [AdventureWorks2019].[Sales].[SalesTerritory]
                  ON [AdventureWorks2019].[Sales].[SalesTerritory].TerritoryID =
[AdventureWorks2019].[Sales].[Customer].TerritoryID
)
SELECT * INTO [dbo].[Dim_Customer] FROM Customer_Source;
ALTER TABLE dbo.Dim Customer
ADD CONSTRAINT Constraint_PK_CustomerID PRIMARY KEY(CustomerID);
Wynik:
(19820 rows affected)
```

b. Dim_Product (**ProductID**, Name, ListPrice, Color, SubCategoryName, CategoryName)

Tabele źródłowe:

- Production.Product
- Production.ProductSubcategory
- Production.ProductCategory

Rozwiązanie:

```
USE [256305];
WITH Product_Source
(
          ProductID,
          [Name],
          ListPrice,
          Color,
          SubCategoryName,
```

```
CategoryName
AS
       SELECT
              ProductID,
              [AdventureWorks2019].[Production].[Product].[Name],
              [AdventureWorks2019].[Production].[Product].[ListPrice],
              [AdventureWorks2019].[Production].[Product].[Color],
              [AdventureWorks2019].[Production].[ProductSubcategory].[Name],
              [AdventureWorks2019].[Production].[ProductCategory].[Name]
       FROM [AdventureWorks2019].[Production].[Product]
              JOIN [AdventureWorks2019].[Production].[ProductSubcategory]
                     ON [AdventureWorks2019].[Production].[Product].ProductSubcategoryID =
[AdventureWorks2019].[Production].[ProductSubcategory].ProductSubcategoryID
              JOIN [AdventureWorks2019].[Production].[ProductCategory]
                     ON [AdventureWorks2019].[Production].[ProductCategory].ProductCategoryID
= [AdventureWorks2019].[Production].[ProductSubcategory].ProductCategoryID
)
SELECT * INTO [dbo].[Dim Product] FROM Product Source;
ALTER TABLE dbo.Dim Product
       ADD CONSTRAINT PK DimProduct ProductID PRIMARY KEY(ProductID)
ALTER TABLE dbo.Dim Product
       ADD CONSTRAINT Check_Product_ListPrice CHECK ([ListPrice]>=(0.00))
Wynik:
(295 rows affected)
       c. Fact Orders (ProductID, CustomerID, OrderDate, ShipDate, OrderQty, UnitPrice,
          UnitPriceDiscount, LineTotal)
Tabele źródłowe:
       Sales.SalesOrderDetail
       Sales.SalesOrderHeader
   Rozwiązanie:
USE [256305];
WITH Orders_Source
       ProductID,
       CustomerID,
       OrderDate,
       ShipDate,
       OrderQty,
       UnitPrice,
       UnitPriceDiscount,
       LineTotal
AS
       SELECT
              ProductID,
              CustomerID,
              OrderDate,
              ShipDate,
              OrderQty,
```

```
UnitPrice,
             UnitPriceDiscount,
             LineTotal
       FROM [AdventureWorks2019].[Sales].[SalesOrderHeader]
             JOIN [AdventureWorks2019].[Sales].[SalesOrderDetail]
                    ON [AdventureWorks2019].[Sales].[SalesOrderDetail].SalesOrderID =
[AdventureWorks2019].[Sales].[SalesOrderHeader].SalesOrderID
SELECT * INTO [dbo].[Fact_Orders] FROM Orders_Source;
ALTER TABLE [dbo].[Fact_Orders]
      ADD CONSTRAINT [Check_FO_UnitPrice] CHECK ([UnitPrice]>=(0.00));
ALTER TABLE [dbo].[Fact_Orders]
      ADD CONSTRAINT [Check_FO_UnitPriceDiscount] CHECK ([UnitPriceDiscount]>=(0.00));
ALTER TABLE [dbo].[Fact_Orders]
      ADD CONSTRAINT [Check_FO_OrderQty] CHECK ([OrderQty]>(0));
ALTER TABLE [dbo].[Fact_Orders]
      ADD CONSTRAINT [Check_FO_ShipDate] CHECK (([ShipDate]>=[OrderDate] OR [ShipDate] IS
NULL))
ALTER TABLE [dbo].[Fact Orders]
      ADD CONSTRAINT [Check_F0_OrderDateDefault] DEFAULT (getdate()) FOR [OrderDate];
(121317 rows affected)
Zdefiniować ograniczenia referencyjne dla tabeli Fact_Orders
   Rozwiązanie:
USE [256305];
ALTER TABLE [dbo].[Fact_Orders]
      ADD CONSTRAINT [FK_FactOrders_To_DimCustomer]
             FOREIGN KEY([CustomerID])
             REFERENCES [dbo].[Dim_Customer] ([CustomerID]);
ALTER TABLE [dbo].[Fact_Orders]
      ADD CONSTRAINT [FK_FactOrders_To_DimProduct]
             FOREIGN KEY([ProductID])
             REFERENCES [dbo].[Dim_Product] ([ProductID]);
Wynik:
Commands completed successfully.
```

- 3. Utworzone tabele napełnić danymi wykorzystując dane w podanych tabelach źródłowych
- 4. Wygenerować raport z danych w utworzonej bazie danych zgodnie z podaną definicją:

Zamówienia ("Nazwisko, imię", Kategoria produktu, Nazwa produktu, Cena)

Rozwiązanie przedstawić w formie tabelarycznej (definicja zapytania i kopia wyniku) oraz w formie wizualnej (2-3 diagramy przygotowane w Tableau wraz z analizą wyników i wnioskami).

Rozwiązanie 1. (zapytanie SQL + fragment wyniku 4-5 rekordów):

```
USE [256305];
WITH Order_Source
       [KlientName],
       [Kategoria produktu],
       [Nazwa Produktu],
       [Cena]
AS
       SELECT
              CONCAT_WS(', ', LastName, FirstName),
              CategoryName,
              [dbo].[Dim_Product].[Name],
              LineTotal
       FROM dbo.Fact_Orders
              JOIN dbo.Dim_Customer
                     ON dbo.Dim_Customer.CustomerID = dbo.Fact_Orders.CustomerID
              JOIN dbo.Dim_Product
                     ON dbo.Dim_Product.ProductID = dbo.Fact_Orders.ProductID
)
SELECT
       IIF(KlientName ='', ' Anonimowy', KlientName) as Klient,
       [Kategoria produktu],
       [Nazwa Produktu],
       [Cena]
FROM Order_Source
ORDER BY
       IIF(KlientName = '', 0, 1) DESC,
       Klient,
       [Kategoria produktu],
       [Nazwa Produktu],
       [Cena];
```

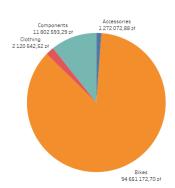
Używam takiej składni, żeby klienci anonimowi (bez imienia nazwiska, regionu) byli na samym końcu tabelki

Klient	Kategoria produktu	Nazwa Produktu	Cena
Adams, Aaron	Accessories	Fender Set - Mountain	21.980000
Adams, Aaron	Accessories	Mountain Bottle Cage	9.990000
Adams, Aaron	Accessories	Water Bottle - 30 oz.	4.990000
Adams, Aaron	Bikes	Mountain-200 Black,	2294.990000
		46	

Rek: 4/121317

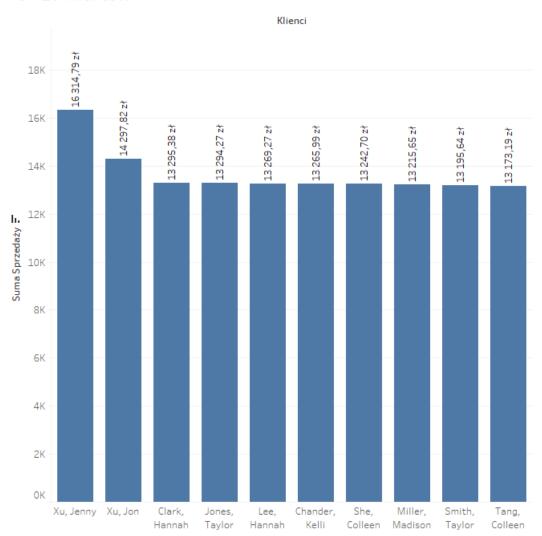
Rozwiązanie 2. (prezentacja wyników analizy danych - Tableau):

Udział kategorii w sprzedaży

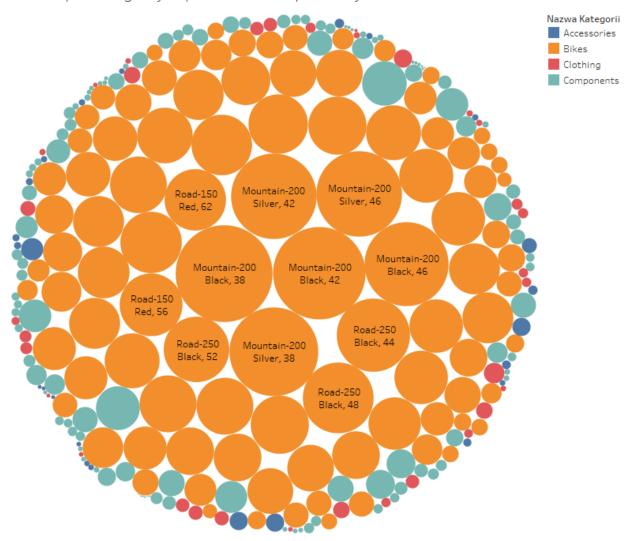


CategoryName
Accessories
Bikes
Clothing
Components

TOP 10 Klientów



Udział poszczególnych produktów w sprzedaży



Wnioski:

Partition over przydaje się przy bardzo niestandardowych kwerendach agregacyjnych i prezentacji wyników, jednak do standardowego agregowania danych group by wystarcza z nadmiarem. Kopiowanie danych przed analizą jest ważne, aby po pierwsze, pracować na kopii danych, a nie na produkcji, a po drugie, pozwala na wykonania wycinka rzeczywistości w danym momencie czasu. Tablau w bardzo przyjazny sposób pozwala analizować dane z bazy danych, i graficznie przedstawiać je na wykresach, pie-chartach czy nawet chmurze

Uwaga:

 Sprawozdanie bez wniosków końcowych nie będzie sprawdzane i tym samym ocena jest negatywna!